HİPERPARAMETRE AYARLI DERİN ÖĞRENME YÖNTEMLERİ İLE ELEKTRİK TÜKETİMİNİN TAHMİNİ

DENİZ CAN TOŞUR

BURDUR,2021

ÖZET

Bu rapor çalışmasında, Multivariable(Çok değişkenli) girişli 2006-2011 arasında bir bölgenin kullandığı elektrik tüketimini ‘Jupyter Notebook’ ile verileri ekrana göstererek daha sonra bu veri setleri ile veri görselleştirmesi, güzelleştirmesi ve düzenlemesi yapılmıştır. RNN Modeli için Multivariable(Çok değişkenli) veri seti kullanılmıştır. Öncelikle modeldede önce kütüphaneler belirlendi daha sonra veri seti ekrana yansıtılıp veri setini işledikten(düzenledikten) sonra grafikler ile güzelleştirme yapılıp modeller oluşturuldu. RNN modelinde gerçek değer ile RNN tahmin modeli kıyaslatıldı. Grafik üzerinde gösterme yöntemini kullandığımız fonksiyonlar Çizgi grafiği için ‘lineplot’, Kutu grafiği için ‘boxplot’, Histogram grafiği için ‘distplot’, Violin(Keman) Grafiği için ‘violinplot’ fonksiyonlarını kullanarak veri seti grafiklere döküldü. Daha sonra veri ön işleme adımları uygulanarak model geliştirildi. Daha sonra ekleme yapılarak jackknife ve bootstrap ile veri arttırma teknikleri kullanıldı. Modelin eğitimi tamamlandıktan sonra k katlamalı çapraz doğrulama(k fold cross validation) ile birlikte GridSearchCV ile doğruluk değerlerini ve tahmin edicileri bulduk.

Anahtar Kelimeler: lineplot, boxplot, distplot, violinplot, RNN, Jackknife, Bootstrap, Kfold Cross Validation, GridSearchCV

ABSTRACT

In this report, between 2006-2011 with multivariate (multivariate) input, firstly, by showing the electricity consumption with 'Jupyter Notebook', data visualization, beautification and arrangement was made in this data area. Multivariate (Multivariate) data set is used for RNN Model. First, libraries were determined in the model, then the models were created after the data set screen was illuminated and the data set was processed (edited) and the models were beautified with graphics. In the RNN model, the real value and the RNN model estimation were compared. Functions using the method of displaying on the chart The data set was converted into the charts using the functions 'lineplot' for line chart, 'boxplot' for box chart, 'distplot' for histogram chart, 'violin chart' for Violin Chart. Later, data pre-processing can be continued model was developed. Then by adding jackknife and bootstrap data increase style query. After completing the model training, we found accuracy pasting and predictors with GridSearchCV along with k-coded validation (cross validation).

Keywords: lineplot, boxplot, distplot, violinplot, RNN, Jackknife, Bootstrap, Kfold Cross Validation, GridSearchCV

1.GİRİŞ

Elektrik tüketimi son yıllarda yaşanan sıkıntılardan birisidir. Elektrik tüketimi hızla arttığından dağılımın doğru bir şekilde bazı aşamalardan geçip tahmin edilmesi gerekmektedir. Elektrik tüketiminde keskin yani doğru bir sonuç elde edebilmemiz için elektrik kullanımını takip etmemiz veya izlememiz gerekmektedir. Gözlemler sonucunda yapacağımız doğru bir tahmin bizi ileriki plansız elektrik tüketimlerini göz önüne alarak gereksiz elektrik dağıtımı önlenebilir. Ancak elektrik tüketimini etkileyen faktörlerin kullanılması sonucunda öngörülemeyen karmaşık bir tahmin modeli oluşabilir. Elektrik tüketimi zamana bağlı bir yapıdadır. Bu nedenle Elektrik tüketiminin tahmin modelini oluşturmak için belli başlı zaman serilerini kullanan yaklaşımlar vardır. Geçmişte kullanılan veriler, zaman serisi analizine dayalı çözümler ile zamana bağlı değişiklikleri ekrana yansıtır. Elektrik tüketimi tahminleri kısa vadeli(saatlik ile 1 hafta arası), orta vadeli (bir hafta ile bir yıl arası), uzun vadeli (bir yıldan fazla) olarak üç modelden oluşmaktadır.

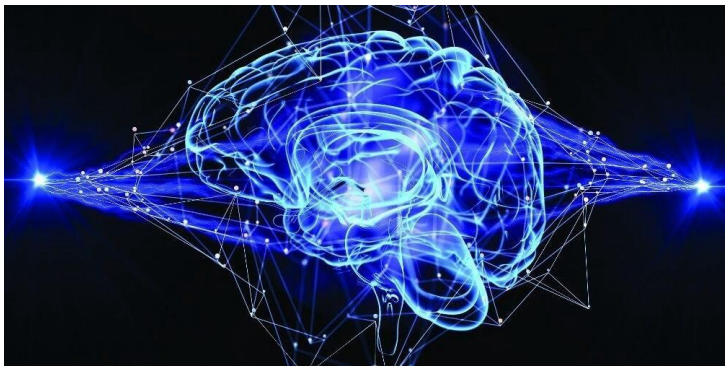

Bu modelleri oluşturma aşamasında yardımımıza Derin Öğrenme yöntemleri ve Makine Öğrenimi Yöntemleri karşımıza çıkıyor. Derin Öğrenme ve Makine Öğrenimi yöntemlerinin çoğu zaman tahmine dayalı modelleme problemleri için bir çözüm anahtarı olduğu bilinmekte. Derin Öğrenme, bilgisayarlara insanların doğal olarak gelen bir şeyi yaptırmayı öğreten bir makine öğrenimi tekniğidir.

2. GENEL BİLGİLER

2.1 Veri Seti

Elektrik tüketimi konusunda tahmin modellerini yapabilmemiz için öncelikle veri setlerine ihtiyacımız bulunmaktadır. Kullanacağımız veri seti 2006-2011 yılları arasında enerji tüketimini gösteren veri seti ele alınmıştır. Veri seti Çok değişkenli veri seti olarak iki girişin toplam verisi sayısı “2884” olarak hesaplandı. Veri seti hazırlanması Derin Öğrenme yönteminin ilk başlarında gelir. Veri seti ne kadar düzenli ise yapılacak işlemler o kadar daha kesin veya daha doğru sonuç elde edilmeye olanak sağlar.

Çok değişkenli veri setinin ilk 5 satırının görseli aşağıdaki gibidir.

1	datetime,Global_active_power,Global_reactive_power,Voltage,Global_intensity,Sub_metering_1,Sub_metering_2,Sub_metering_3,Sub_metering_4
2	2006-12-16,1209.1760000000004,34.921999999999976,93552.53000000006,5180.800000000008,0.0,546.0,4926.0,14680.933319299998
3	2006-12-17,3390.46,226.0059999999994,345725.32000000024,14398.59999999998,2033.0,4187.0,13341.0,36946.66673200004
4	2006-12-18,2203.825999999997,161.79199999999966,347373.64000000036,9247.199999999988,1063.0,2621.0,14018.0,19028.43328100003
5	2006-12-19,1666.1940000000006,150.94199999999978,348479.0100000004,7094.000000000014,839.0,7602.0,6197.0,13131.900043499994

Veriler aşağıya doğru devam etmektedir.

3. MATERYAL VE YÖNTEM

3.1 RNN MODELİ

Yinelenen Sinir Ağı, dahili belleğe sahip ileri beslemeli sinir ağının bir genellemesidir. RNN, her veri girişi için aynı işlevi yerine getirdiği için doğası gereği tekrarlanırken, mevcut girişin çıktısı son bir hesaplamaya bağlıdır. Çıktı üretildikten sonra kopyalanır ve tekrarlayan ağa geri gönderilir. Karar vermek için, önceki girdiden öğrendiği mevcut girdiyi ve çıktıyı dikkate alır.

İleri beslemeli sinir ağlarının aksine, RNN'ler giriş sıralarını işlemek için dahili durumlarını (bellek) kullanabilir. Bu, onları bölümlere ayrılmamış, bağlantılı el yazısı tanıma veya konuşma tanıma gibi görevlere uygulanabilir kılar. Diğer sinir ağlarında tüm girdiler birbirinden bağımsızdır. Ancak RNN'de tüm girdiler birbiriyle ilişkilidir.

Örnek bir RNN modeli aşağıdaki gibi çalışır.

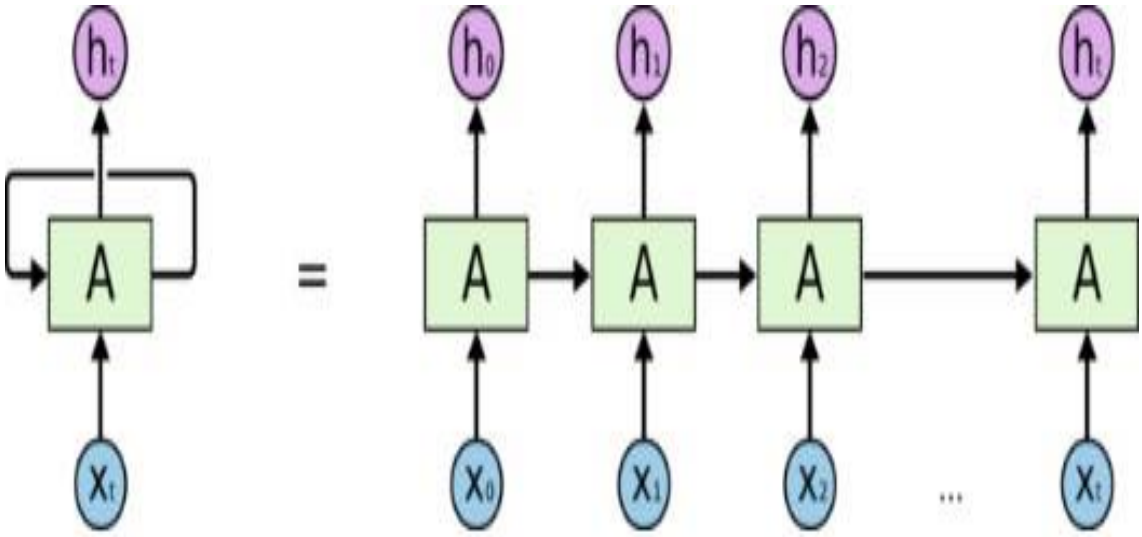

An unrolled recurrent neural network.

3.3.1 Kütüphaneler ve Veri seti İşlemleri

In [3]:
```
# Kütüphaneleri içe aktarma
import os
os.environ['PYTHONHASHSEED'] = '0'
import random as rn
import numpy as np
np.random.seed(1)
rn.seed(3)
import tensorflow
tensorflow.random.set_seed(2)
import pandas as pd
import matplotlib.pyplot as plt
from keras.models import Sequential, load_model
from keras.layers.core import Dense
from keras.layers.recurrent import SimpleRNN
from keras import optimizers
from keras.callbacks import EarlyStopping
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_squared_error, r2_score
from math import sqrt
import datetime as dt
import time
plt.style.use('ggplot')
```

- Öncelikle gerekli kütüphaneleri import ediyoruz ve as ile kısaltıyoruz. İmport ettiğimiz kütüphaneler sırasıyla; numpy, pandas, tensorflow, seaborn, matplotlib, keras, sklearn şeklinde devam ediyor.

Veri Ön İşleme

In [3]:
```
df = pd.read_csv("household_daily.csv",header=0,infer_datetime_format=True)
df.head()
```

Out[3]:

	datetime	Global_active_power	Global_reactive_power	Voltage	Global_intensity	Sub_metering_1	Sub_metering_2	Sub_m
0	2006-12-16	1209.176	34.922	93552.53	5180.8	0.0	546.0	
1	2006-12-17	3390.460	226.006	345725.32	14398.6	2033.0	4187.0	
2	2006-12-18	2203.826	161.792	347373.64	9247.2	1063.0	2621.0	
3	2006-12-19	1666.194	150.942	348479.01	7094.0	839.0	7602.0	
4	2006-12-20	2225.748	160.998	348923.61	9313.0	0.0	2648.0	

- Pd.read_csv ile csv dosyasının adını tanımladık(house_daily.csv) ve df'ye eşitledik.
- Df.head metodu ile veri setinin ilk 5 satırını ekrana yazdırdık

Tarih Saat Sütunlarını Yeniden Biçimlendirelim

In [4]:
```
# Yılın Ayı, Günü, Saati vb. Gibi Tüm Verileri Çıkartıyoruz

df["Ay"] = pd.to_datetime(df["datetime"]).dt.month
df["Yil"] = pd.to_datetime(df["datetime"]).dt.year
df["Tarih"] = pd.to_datetime(df["datetime"]).dt.date
df["Saat"] = pd.to_datetime(df["datetime"]).dt.time
df["Hafta"] = pd.to_datetime(df["datetime"]).dt.week
df["Gün"] = pd.to_datetime(df["datetime"]).dt.day_name()
df = df.set_index("datetime")
df.index = pd.to_datetime(df.index)
df.head(5)
```

- Öncelikle veri setimiziin kısaltması olan df yi dataset'e eşitliyoruz.
- dataset içerisine başlığımızı yazıp(Ay) hangi türden veri çekeceğini yazıyoruz burdaki işlemde 'mont' yani ay verilerini buraya yazmasını istedik.
- dataset içerisine başlığımızı yazıp(Yil) hangi türden veri çekeceğini yazıyoruz burdaki işlemde 'year' yani yıl verilerini buraya yazmasını istedik.
- dataset içerisine başlığımızı yazıp(Tarih) hangi türden veri çekeceğini yazıyoruz burdaki işlemde 'date' yani tarih verilerini buraya yazmasını istedik.
- dataset içerisine başlığımızı yazıp(Saat) hangi türden veri çekeceğini yazıyoruz burdaki işlemde 'time' yani saat verilerini buraya yazmasını istedik.
- dataset içerisine başlığımızı yazıp(Hafta) hangi türden veri çekeceğini yazıyoruz burdaki işlemde 'week' yani hafta verilerini buraya yazmasını istedik.
- dataset içerisine başlığımızı yazıp(Gün) hangi türden veri çekeceğini yazıyoruz burdaki işlemde 'day_name()' yani gün verilerini buraya yazmasını istedik.
- set_index() işlevi, var olan sütunları kullanarak veri çerçevesi dizinini ayarlamak için kullanılır.("Datetime") ile bu veri çerçevesine bir satır etiketi(başlık) olarak ayarlandı.
- to_datetime, dize tarih saatini python tarih saat nesnesine dönüştürülmesini sağladı.
- dataset.head(5) ile sadece işlemlerin hepsini yazdırmak yerine sadece ilk 5 satırını ekrana yazdırdık.

Çıktısı;

datetime	Global_active_power	Global_reactive_power	Voltage	Global_intensity	Sub_metering_1	Sub_metering_2	Sub_metering_3	Sub_metering_4	Ay	Y
2006-12-16	1209.176	34.922	93552.53	5180.8	0.0	546.0	4926.0	14680.933319	12	200
2006-12-17	3390.460	226.006	345725.32	14398.6	2033.0	4187.0	13341.0	36946.666732	12	200
2006-12-18	2203.826	161.792	347373.64	9247.2	1063.0	2621.0	14018.0	19028.433281	12	200
2006-12-19	1666.194	150.942	348479.01	7094.0	839.0	7602.0	6197.0	13131.900043	12	200
2006-12-20	2225.748	160.998	348923.61	9313.0	0.0	2648.0	14063.0	20384.800011	12	200

- Sütunlar sağa doğru devam etmektedir.

3.3.2 Grafikler

Grafikler, çeşitli yapay ve doğal süreçler tarafından üretilen zengin ve karmaşık verileri temsil etmek için kullanılan bir araçtır. Bir grafik , düğümlere (bilgiyi tutan varlıklar) ve kenarlara (aynı zamanda bilgiyi tutan düğümler arasındaki bağlantılar) sahip olan ve bu nedenle, ilişkisel bir doğanın yanı sıra bir bileşim niteliğine sahip olan yapılandırılmış bir veri türü olarak düşünülebilir. Grafik, verileri yapılandırmanın bir yoludur, ancak kendi başına bir veri noktası da olabilir. Grafikler, bir Öklid dışı veri türüdür , yani görüntüler, metin ve ses gibi diğer veri türlerinin aksine 3B olarak bulunurlar. Grafikler, üzerlerinde gerçekleştirilebilecek olası eylemleri ve analizleri sınırlayan belirli özelliklere sahip olabilir. Bu bölümde veri setimizi grafiklere dökmeyi göstereceğiz.

Global_active_power'ın Grafikleri

Çizgi Grafiği

Çizgi grafiği, verileri her bir değerin sıklığını gösteren bir sayı doğrusu üzerinde noktalar veya onay işaretleri olarak görüntüleyen bir grafik olarak tanımlanabilir.

```
In [5]:
#Çizgi Grafiği
sns.lineplot(x=df["Tarih"], y=df["Global_active_power"], data=df)
sns.set(rc={'figure.figsize':(15,6)})
plt.xlabel("Tarih")
plt.ylabel("Mega Watt cinsinden enerji")
plt.legend()
plt.title("Yillara Göre Enerji Tüketimi")
```

- sns.lineplot ile seaborn kütüphanesinden çizgi grafiğini kullandık. Bu grafiğin x ve y koordinatlarını belirlemek için x değerine veri setmizden 'Tarih' kısmını yazdırdık, y değerine de veri setmizden 'Global_active_power' kısmını kullanıp yazdırdık.
- Daha sonra sns.set ile grafiğin en boy oranını belirledik.
- Grafiğin x koordinatı altına etiket olarak 'Tarih' yazdırdık.
- Grafiği y koordinatı altınada etiket olarak 'Mega Watt cinsinden enerji' yazdırdık.
- plt.legend() diyerek grafiğimizin otomatik olarak oluşturulmasını sağladık.
- Title metodunu kullanarak grafiğe başlık(Yillara Göre Enerji Tüketimi) yazdırdık.

Çıktısı;

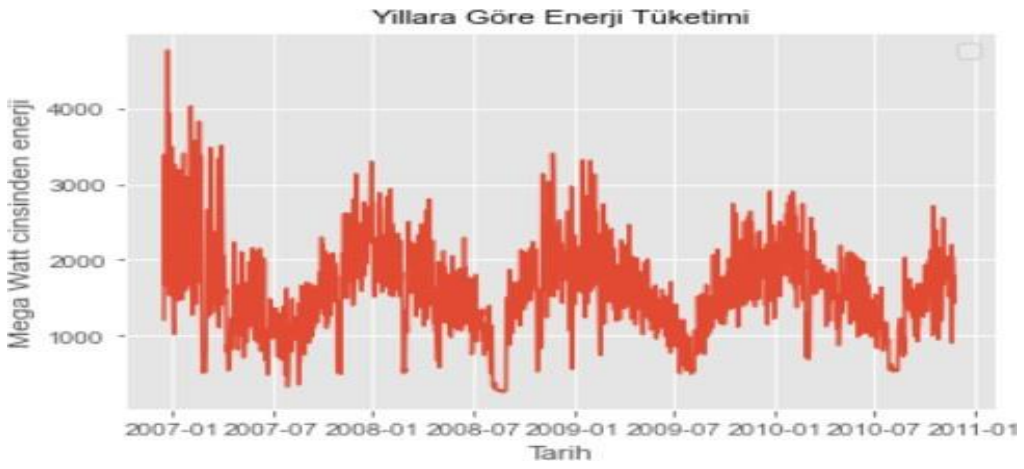

Kutu Grafiği

Kutu grafiği, ilgili değişken bakımından veri için hazırlanan beş sayılı özetleme tablosu gösterimini grafiksel olarak özetlemeye dayalıdır. Özellikle merkezsel konum, yayılma, çarpıklık ve basıklık yönünden verileri özetlemek ve aykırı değerleri tanımlamak için kullanılır.

```
In [6]:
#Kutu Grafiği
sns.boxplot(x=df["Yil"], y=df["Global_active_power"], data=df)
sns.set(rc={'figure.figsize':(15,6)})
plt.xlabel("Tarih")
plt.ylabel("Mega Watt cinsinden enerji")
plt.legend()
plt.title("Yillara Göre Enerji Tüketimi")
```

- sns.boxplot ile seaborn kütüphanesinden kutu grafiğini kullandık. Bu grafiğin x ve y koordinatlarını belirlemek için x değerine veri setmizden 'Yil' kısmını yazdırdık, y koordinatına da veri setmizden 'Global_active_power' kısmını kullanıp yazdırdık.
- Daha sonra sns.set ile grafiğin en boy oranını belirledik.
- Grafiğin x koordinatı altına etiket olarak 'Tarih' yazdırdık.
- Grafiği y koordinatı altınada etiket olarak 'Mega Watt cinsinden enerji' yazdırdık.
- plt.legend() diyerek grafiğimizin otomatik olarak oluşturulmasını sağladık.
- Son olarakta Grafiğe bir başlık eklemek için Title metodu ile 'Yillara Göre Enerji Tüketimi' yazdırıyoruz.

Çıktısı;

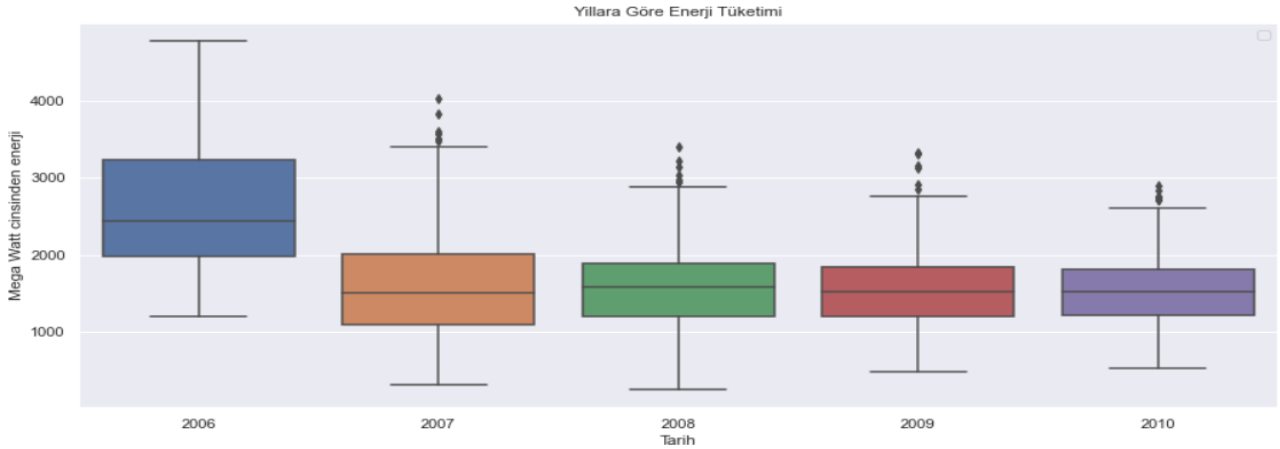

Histogram Grafiği

Çubuk Grafiğine benzer , ancak histogram sayıları aralıklar halinde gruplandırır . Her çubuğun yüksekliği, her bir aralığa kaç tane düştüğünü gösterir. Ve hangi aralıkları kullanacağımıza biz karar veririz.

```
In [7]:
1 #Histogram Grafiği
2 sns.distplot(df["Global_active_power"])
3 plt.title("Enerji Dağılımı")
```

- sns.distplot modülü üzerinde çizgi bulunan bir histogram grafiği göstermemiz sağlar. Bu modül ile veri setindeki Global_active_power değerlerini histogram grafiğine aktarmış olundu.
- Grafiğimize başlık olarak plt.title metodunu kullanıp 'Enerji Dağılımı' başlığı attık.

Çıktısı;

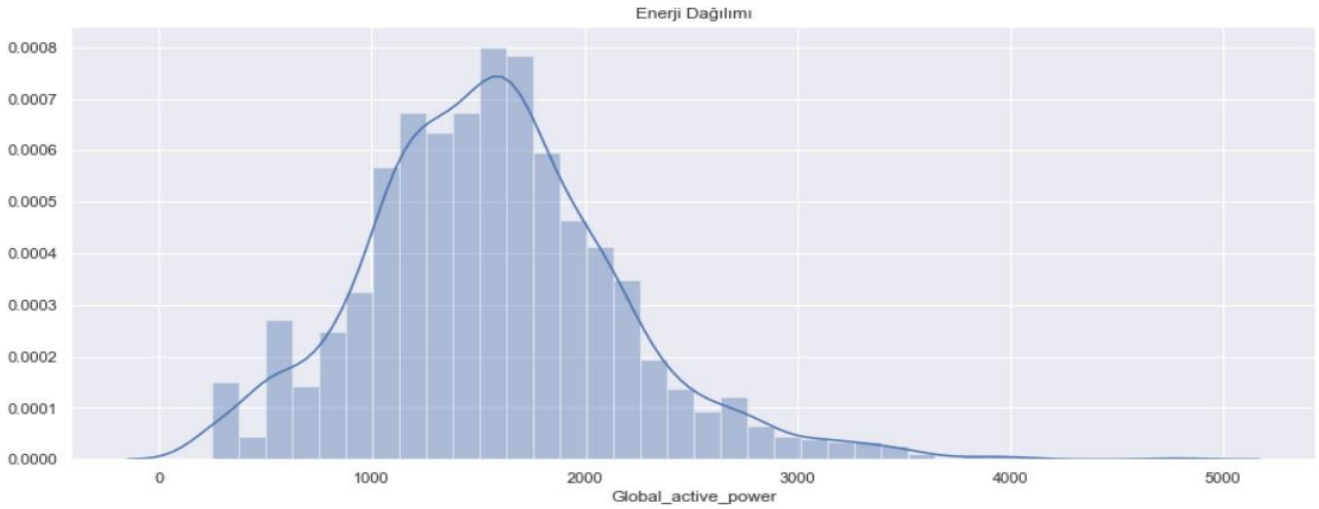

Violin(Keman) Grafiği

Bir keman grafiği , sayısal verileri çizme yöntemidir. Her bir tarafa döndürülmüş bir çekirdek yoğunluğu grafiğinin eklenmesiyle bir kutu grafiğine benzer . Keman grafikleri , genellikle bir çekirdek yoğunluğu tahmincisi tarafından düzleştirilen farklı değerlerde verilerin olasılık yoğunluğunu göstermeleri dışında kutu grafiklerine benzer. Tipik olarak bir keman grafiği, bir kutu grafiğindeki tüm verileri içerir. Bir keman grafiğinin birden fazla katmanı olabilir. Örneğin, dış şekil tüm olası sonuçları temsil eder. İçerideki bir sonraki katman, zamanın% 95'inde oluşan değerleri temsil edebilir. İçerideki bir sonraki katman (varsa), zamanın% 50'sinde oluşan değerleri temsil edebilir.

```
In [8]:
1 #Violin(keman) Grafiği
2 sns.set_style('whitegrid')
3 sns.violinplot(x = 'Yil', y = 'Global_active_power', data = df)
```

- Öncelikle stil setinden arka plan olarak beyaz ızgara(whitegrid) rengini seçtik.
- Sns.violinplot ile seaborn kütüphanesinden violin grafiğini kullandık. Bu grafiğin x ve y koordinatlarını belirlemek için x değerine veri setimizden 'Yil' kısmını kullandık, y koordinatınada veri setimizden 'Global_active_power' kısmını kullanıp yazdırdık.

  Çıktısı;

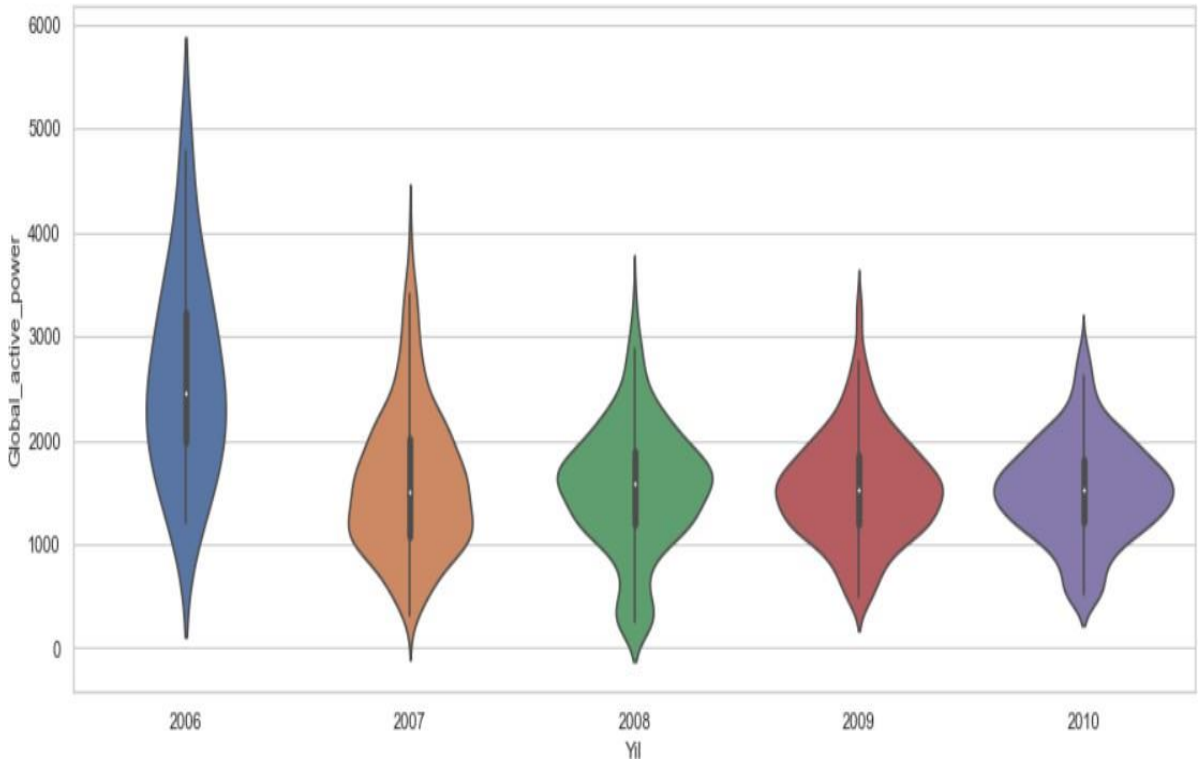

Global_reactive_power'ın Grafikleri

Çizgi Grafiği

```
In [9]:
#Çizgi Grafiği
sns.lineplot(x=df["Tarih"], y=df["Global_reactive_power"], data=df)
sns.set(rc={'figure.figsize':(15,6)})
plt.xlabel("Tarih")
plt.ylabel("Mega Watt cinsinden enerji")
plt.grid(True)
plt.legend()
plt.title("Yillara Göre Enerji Tüketimi")
```

```
No handles with labels found to put in legend.
```

- sns.lineplot ile seaborn kütüphanesinden çizgi grafiğini kullandık. Bu grafiğin x ve y koordinatlarını belirlemek için x değerine veri setmizden 'Tarih' kısmını yazdırdık, y değerine de veri setmizden 'Global_reactive_power' kısmını kullanıp yazdırdık.
- Daha sonra sns.set ile grafiğin en boy oranını belirledik.
- Grafiğin x koordinatı altına etiket olarak 'Tarih' yazdırdık.
- Grafiği y koordinatı altınada etiket olarak 'Mega Watt cinsinden enerji' yazdırdık.
- Grafikte ızgara çizgilerinin gözükmesini istediğimiz için 'plt.grid(True)' kısmının içini doğru(true) yaptık.
- plt.legend() diyerek grafiğimizin otomatik olarak oluşturulmasını sağladık.
- Title metodunu kullanarak grafiğe başlık(Yillara Göre Enerji Tüketimi) yazdırdık.

  Çıktısı;

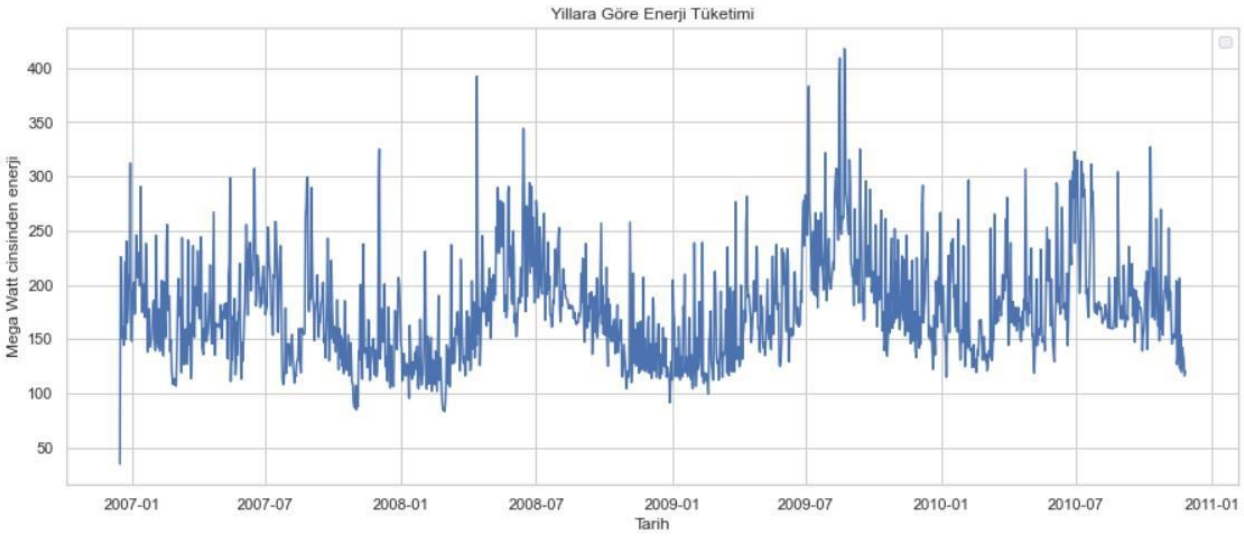

Kutu Grafiği

```
In [10]:
1  #Kutu Grafiği
2  sns.boxplot(x=df["Yil"], y=df["Global_reactive_power"], data=df)
3  sns.set(rc={'figure.figsize':(15,6)})
4  plt.xlabel("Tarih")
5  plt.ylabel("Mega Watt cinsinden enerji")
6  plt.legend()
7  plt.title("Yillara Göre Enerji Tüketimi")
```

```
No handles with labels found to put in legend.
```

- sns.boxplot ile seaborn kütüphanesinden kutu grafiğini kullandık. Bu grafiğin x ve y koordinatlarını belirlemek için x değerine veri setmizden 'Yil' kısmını yazdırdık, y koordinatına da veri setmizden 'Global_reactive_power' kısmını kullanıp yazdırdık.
- Daha sonra sns.set ile grafiğin en boy oranını belirledik.
- Grafiğin x koordinatı altına etiket olarak 'Tarih' yazdırdık.
- Grafiği y koordinatı altınada etiket olarak 'Mega Watt cinsinden enerji' yazdırdık.
- plt.legend() diyerek grafiğimizin otomatik olarak oluşturulmasını sağladık.
- Son olarakta Grafiğe bir başlık eklemek için Title metodu ile 'Yillara Göre Enerji Tüketimi' yazdırıyoruz.

  Çıktısı;

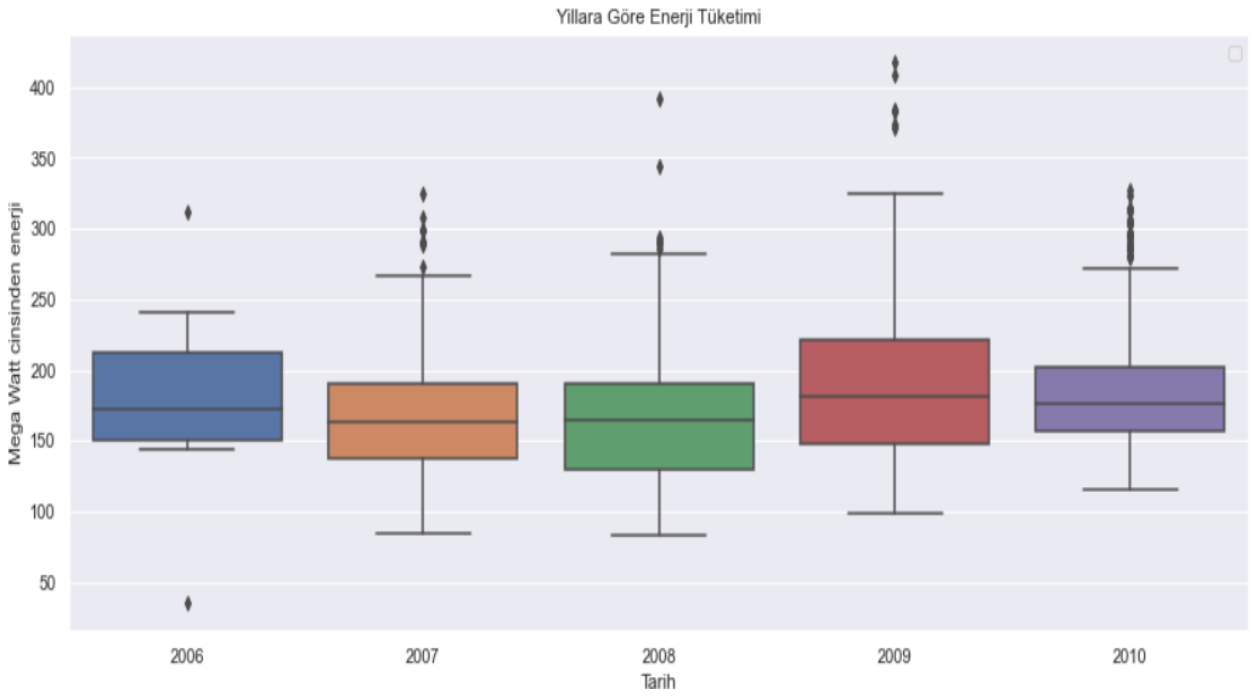

Histogram Grafiği

```
In [11]:
1 #Histogram Grafiği
2 sns.distplot(df["Global_reactive_power"])
3 plt.title("Enerji Dağılımı")
```

- sns.distplot modülü üzerinde çizgi bulunan bir histogram grafiği göstermemiz sağlar. Bu modül ile veri setindeki Global_reactive_power değerlerini histogram grafiğine aktarmış olundu.
- Grafiğimize başlık olarak plt.title metodunu kullanıp 'Enerji Dağılımı' başlığı attık.

  Çıktısı;

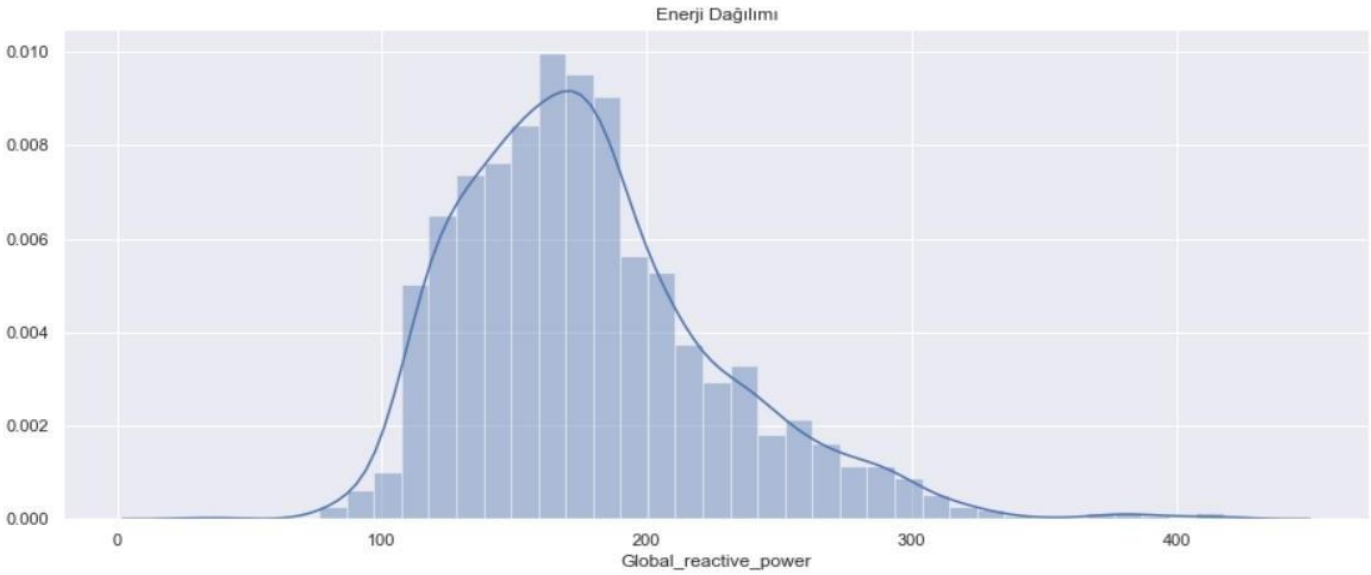

Violin(Keman) Grafiği

```
In [12]:
1 #Violin(keman) Grafiği
2 sns.set_style('whitegrid')
3 sns.violinplot(x = 'Yil', y = 'Global_reactive_power', data = df)
```

- Öncelikle stil setinden arka plan olarak beyaz ızgara(whitegrid) rengini seçtik.
- Sns.violinplot ile seaborn kütüphanesinden violin grafiğini kullandık. Bu grafiğin x ve y koordinatlarını belirlemek için x değerine veri setimizden 'Yil' kısmını kullandık, y koordinatınada veri setimizden 'Global_reactive_power' kısmını kullanıp yazdırdık.

Çıktısı;

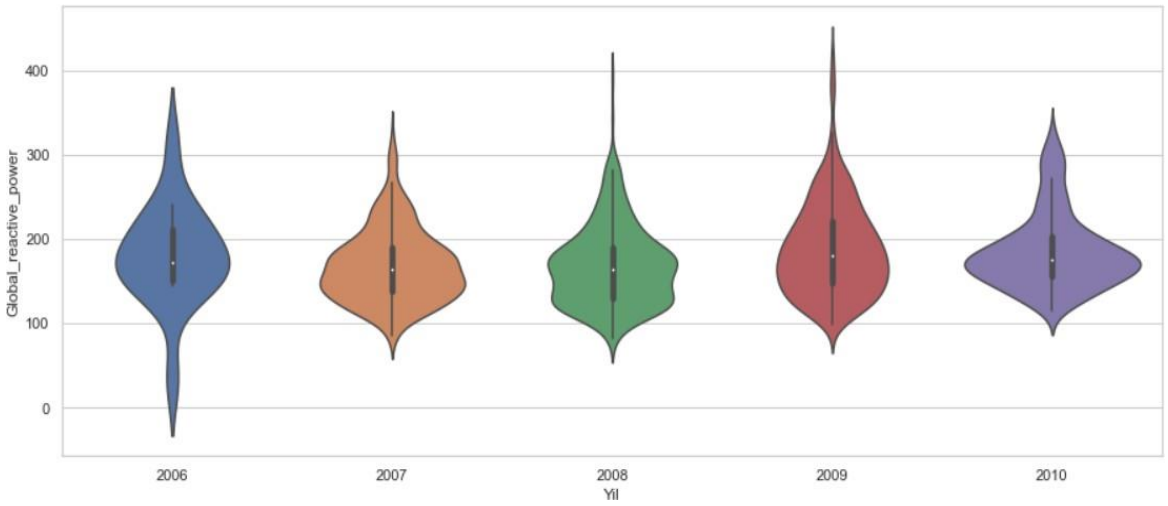

Voltage'in Grafikleri

Çizgi Grafiği

```
In [14]:
1  #Çizgi Grafiği
2  sns.lineplot(x=df["Tarih"], y=df["Voltage"], data=df)
3  sns.set(rc={'figure.figsize':(15,6)})
4  plt.xlabel("Tarih")
5  plt.ylabel("Mega Watt cinsinden enerji")
6  plt.legend()
7  plt.title("Yillara Göre Enerji Tüketimi")

No handles with labels found to put in legend.

Out[14]: Text(0.5, 1.0, 'Yillara Göre Enerji Tüketimi')
```

- sns.lineplot ile seaborn kütüphanesinden çizgi grafiğini kullandık. Bu grafiğin x ve y koordinatlarını belirlemek için x değerine veri setmizden 'Tarih' kısmını yazdırdık, y değerine de veri setmizden 'Voltage kısmını kullanıp yazdırdık.
- Daha sonra sns.set ile grafiğin en boy oranını belirledik.
- Grafiğin x koordinatı altına etiket olarak 'Tarih' yazdırdık.
- Grafiği y koordinatı altınada etiket olarak 'Mega Watt cinsinden enerji' yazdırdık.
- plt.legend() diyerek grafiğimizin otomatik olarak oluşturulmasını sağladık.
- Title metodunu kullanarak grafiğe başlık(Yillara Göre Enerji Tüketimi) yazdırdık.

Çıktısı;

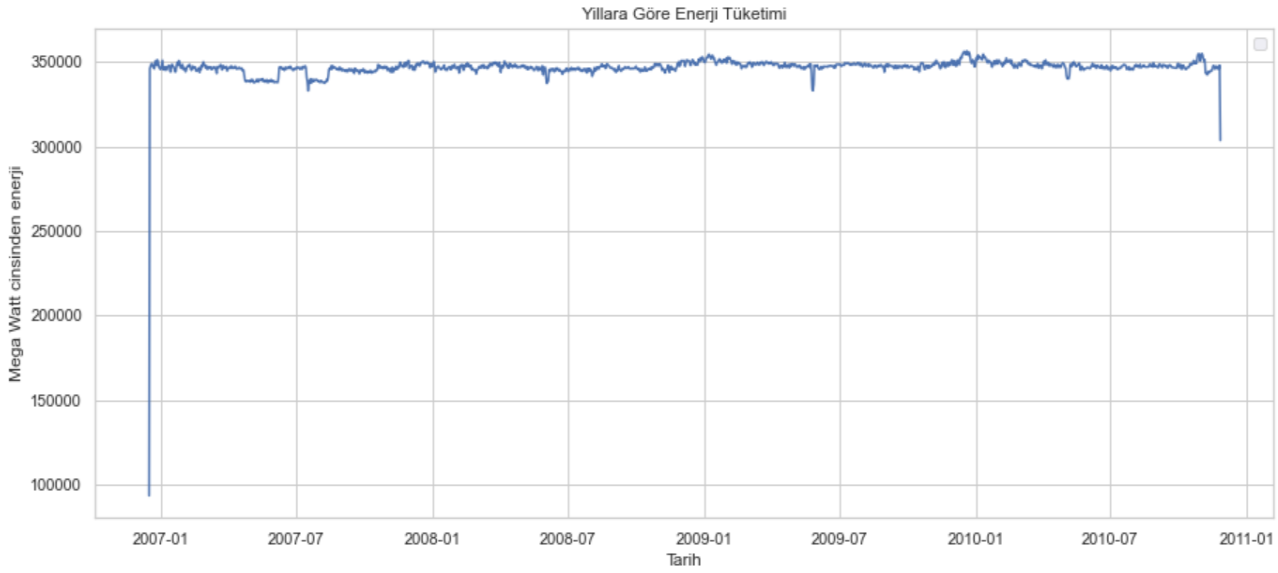

Histogram Grafiği

```
In [15]:  1  #Histogram Grafiği
          2  sns.distplot(df["Voltage"])
          3  plt.title("Enerji Dağılımı")

Out[15]: Text(0.5, 1.0, 'Enerji Dağılımı')
```

- sns.distplot modülü üzerinde çizgi bulunan bir histogram grafiği göstermemiz sağlar. Bu modül ile veri setindeki Voltage'nin değerlerini histogram grafiğine aktarmış olundu.
- Grafiğimize başlık olarak plt.title metodunu kullanıp 'Enerji Dağılımı' başlığı attık.

Çıktısı;

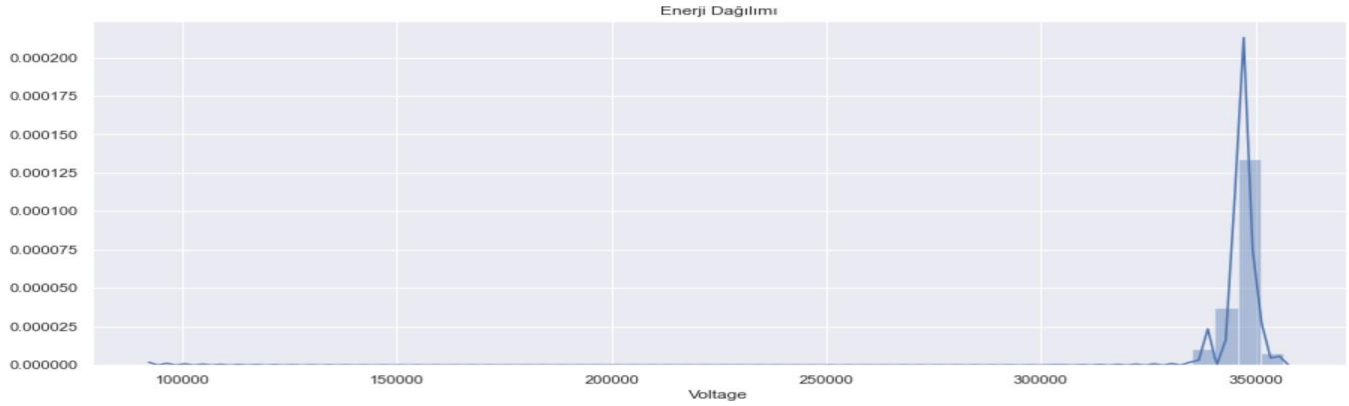

3.3.3 RNN Modeli Oluşturma

```
In [13]:
1 # Korelasyon matrisi
2 df.corr()['Global_active_power']
```

```
Out[13]: Global_active_power      1.000000
         Global_reactive_power    0.042327
         Voltage                  0.065265
         Global_intensity         0.999181
         Sub_metering_1           0.545054
         Sub_metering_2           0.482796
         Sub_metering_3           0.734302
         Sub_metering_4           0.887348
         Ay                      -0.087049
         Yil                     -0.084846
         Hafta                   -0.086835
         Name: Global_active_power, dtype: float64
```

- Veri seti çerçevesindeki tüm sütunların ikili korelasyonunu bulmak için df.corr metodunu kullandık.
- Global_active_power'a göre ikili korelasyon matrisini bulduk ve ekrana yazdırdık.

```
In [17]:
1 # Korelasyon matrisi
2 df.corr()['Global_reactive_power']
```

```
Out[17]: Global_active_power      0.042327
         Global_reactive_power    1.000000
         Voltage                  0.052400
         Global_intensity         0.064038
         Sub_metering_1           0.318793
         Sub_metering_2           0.184432
         Sub_metering_3           0.036932
         Sub_metering_4          -0.099339
         Ay                       0.084706
         Yil                      0.157104
         Hafta                    0.090896
         Name: Global_reactive_power, dtype: float64
```

- Veri seti çerçevesindeki tüm sütunların ikili korelasyonunu bulmak için df.corr metodunu kullandık.
- Global_reactive_power'a göre ikili korelasyon matrisini bulduk ve ekrana yazdırdık.

```
In [18]:
# Korelasyon matrisi
df.corr()['Voltage']
```

```
Out[18]:
Global_active_power      0.065265
Global_reactive_power    0.052400
Voltage                  1.000000
Global_intensity         0.054957
Sub_metering_1          -0.003385
Sub_metering_2          -0.011267
Sub_metering_3           0.099149
Sub_metering_4           0.051747
Ay                      -0.054016
Yil                      0.208007
Hafta                   -0.051904
Name: Voltage, dtype: float64
```

- Veri seti çerçevesindeki tüm sütunların ikili korelasyonunu bulmak için df.corr metodunu kullandık.
- Voltage'ye göre ikili korelasyon matrisini bulduk ve ekrana yazdırdık.

```
In [19]:
print(df.describe().Global_active_power)
df.drop(df[df['Global_active_power']==0].index, inplace = True)
#Hacim değeri 0 olan satırları düşürelim
```

```
count    1442.000000
mean     1567.839069
std       597.306856
min       250.298000
25%      1176.195000
50%      1543.253000
75%      1894.467500
max      4773.386000
Name: Global_active_power, dtype: float64
```

- df.describe() metodu sayısal verilere sahip olan sütunların max, min , std…gibi istatiksel değerlerini döndürür.
- Bu yüzden veri setinde olan Global_active_power'dan daha çok bilgi edinilmek için kullanıldı ve print ile ekrana yazdırdık.
- Global_active_power'da drop metodu ile null(Boş veya sıfır) olan değerleri çıkarttık.
- Çıktısı yukarıdaki gibidir.

In [14]:
```
print(df.describe().Global_reactive_power)
df.drop(df[df['Global_reactive_power']==0].index, inplace = True)
#Hacim değeri 0 olan satırları düşürelim
```

```
count    1442.000000
mean      178.004759
std        48.881691
min        34.922000
25%       143.063000
50%       171.199000
75%       202.548500
max       417.834000
Name: Global_reactive_power, dtype: float64
```

- df.describe() metodu sayısal verilere sahip olan sütunların max, min , std…gibi istatiksel değerlerini döndürür.
- Bu yüzden veri setinde olan Global_reactive_power'dan daha çok bilgi edinilmek için kullanıldı ve print ile ekrana yazdırdık.
- Global_reactive_power'da drop metodu ile null(Boş veya sıfır) olan değerleri çıkarttık.
- Çıktısı yukarıdaki gibidir.

In [21]:
```
print(df.describe().Voltage)
df.drop(df[df['Voltage']==0].index, inplace = True)
#Hacim değeri 0 olan satırları düşürelim
```

```
count      1442.000000
mean     346600.529542
std        7375.850040
min       93552.530000
25%      345736.802500
50%      346979.430000
75%      348283.367500
max      356306.410000
Name: Voltage, dtype: float64
```

- df.describe() metodu sayısal verilere sahip olan sütunların max, min , std…gibi istatiksel değerlerini döndürür.
- Bu yüzden veri setinde olan Voltage'den daha çok bilgi edinilmek için kullanıldı ve print ile ekrana yazdırdık.
- Voltage'da drop metodu ile null(Boş veya sıfır) olan değerleri çıkarttık.
- Çıktısı yukarıdaki gibidir.

In [30]:
```
# Erken durdurma kurma
earlystop = EarlyStopping(monitor='val_loss', min_delta=0.0001, patience=80,  verbose=1, mode='min
callbacks_list = [earlystop]
```

- Öncelikle earystop(Erken durdurma) metodunu uyguluyoruz.
- Bu işlemi eğer RNN modelin doğrulama veri kümesindeki performansı azalmaya başlarsa bu sayede earlystop ile erken durduma işlemi yapılacak.
- Daha sonra earlystop'u callbacks_list'e eşitliyoruz.

JACKKNİFE BÖLÜMÜ

In [62]:
```
def jackknife(x, func, variance = False):
    N = len(x)
    pos = np.arange(N)
    values = [func(x[pos != i]) for i in pos]
    jack = np.sum(values)/N

    if variance:
        values = [np.power(func(x[pos != i]) - jack, 2.0) for i in pos]
        var = (N-1)/N * np.sum(values)
        return jack, var
    else:
        return jack
```

In [63]:
```
x = np.random.normal(0, 2, 100)
print(x.std())
jackknife(x, np.std, True)
```

```
1.77031242766317
```

Out[63]: (1.7701752552752565, 0.016423430647735153)

- Öncelikle def ile jackknife'ı tanımlıyoruz.
- x'in uzunluğunu N'ye eşitliyoruz.
- x'i fonksiyon alarak döngüye sokuyoruz ve bunu valuese eşitliyoruz.
- Np.sum ile oluşan vales'in satır ve sütunlarını toplayıp N'e bölüyoruz ve bunu jack'e eşitliyoruz.
- İf koşulu ile varyans diyoruz.
- x fonksiyonunun ilk dizideki dizi öğesi, ikinci öğedeki öğenin gücüne yükseltilir ve çıkan sonuçtan jack'i çıkarıp döngüye sokuyoruz.
- (N-1)/N işlemini yapıp valuesin satır ve sütunlarını topladığımız kodu yani np.sum(values) ile çarpıyoruz.
- 2. Kod bloğunda ise rastgele sayı üretiyoruz ve bunu x'e eşitliyoruz.
- Print ile x'in standart sapma sonucunu ve hemen altında jackknife ile jackknife'ın sonucunu ekrana yansıtıyoruz.

BOOTSTRAPPİNG BÖLÜMÜ

In [64]:
```python
def bootstrapping(x, n_samples, func=np.mean):
    y = x.copy()
    N = len(y)
    population = []

    for i in range(n_samples):
        population.append(func(np.random.choice(y, N, replace=True)))

    return np.array(population)
```

- Öncelikle def ile bootstrapping'i tanımlıyoruz.
- X değerini x.copy() ile kopyalayıp y'ye eşitliyoruz.
- len(y) ile y'nin uzunuğunu N'e eşitliyoruz.
- Population dizisi tanımlıyoruz.
- Döngü oluşturup population içerisinde fonksiyon ile y ve N içerisinde rastgele seçilen bir öğeyi döndürmesini sağlıyoruz.

In [65]:
```python
def histogram(values, n_bins=100):
    xmax = values.max()
    xmin = values.min()
    delta  = (xmax-xmin)/n_bins

    counts = np.zeros(n_bins+1, dtype='int')

    for value in values:
        val_bin = np.around((value-xmin)/delta).astype('int')
        counts[val_bin] += 1.0

    bins = xmin+delta*np.arange(n_bins+1)

    return bins, counts/values.shape[0]
```

- Histogram'ı tanımlıyoruz.
- xmax bizim values'in max değeri.
- xmin de bizim values'in min değerini temsil ediyor.
- Matematiksel işlem yapıp deltaya eşitliyoruz.
- Sıfırlar ile dolu dizi döndürüp counts'a eşitliyoruz.
- Döngü oluşturup matematiksel ifade yazıyoruz ve onuda np.around ile yuvarlama işlemi yapıp val_bin'e eşitliyoruz.
- np.arange ile dizi oluşturuyoruz ve xmin,delta ile matematiksel işleme sokuyoruz.

```
In [66]: 1 x = np.random.normal(0, 2, size=100)

In [67]: 1 boot = bootstrapping(x, 1000)

In [68]: 1 x.mean()
Out[68]: 0.3055895552403970 5
```

- Rastgele sayı üretiyoruz ve bunu x'e eşitliyoruz.
- Bootstrapping ile sıradan parametrik olmayan önyüklemeyi uyguladık ve aralığını x ile 1000 arasında seçtik ve boot'a eşitledik.
- X.mean() ile aritmetik ortalamayı hesapladık ve çıktısını ekrana gönderdi sistem.

```
In [69]: 1 x.std()
Out[69]: 1.8639896349099911

In [70]: 1 bins, counts = histogram(boot)
```

- x.std() yazıp x'in standart sapmasını ekrana yansıtıyoruz.
- boot'un histogramını bins ve counts'a eşitliyoruz.

```
In [71]:
1 plt.plot(bins, counts)
2 plt.vlines(x=boot.mean(), ymin=0, ymax=counts.max(), label='mean')
3 plt.vlines(x=boot.mean()+boot.std(), ymin=0, ymax=counts.max(), label='std', linestyles='--')
4 plt.vlines(x=boot.mean()-boot.std(), ymin=0, ymax=counts.max(), label='std', linestyles='--')
```

- plt ile pyplot kütüphanesini kullanacağız.
- Plt.plot() içerisine bins ve counts değerlerimizi yazdık.
- İlk Plt.vlines ile boot.mean yani orta bölüme y ekseni boyunca kalın cizgi çiziyoruz.
- İkinci Plt.vlines'da boot.means ile boot.std(boot'un standart sapması)'nı topladığımız yere y ekseni boyunca kesik çizgi çiziyoruz.
- Üçüncü Plt.vlines'da boot.means ile boot.std(boot'un standart sapması)'nı çıkardığımız yere y ekseni boyunca kesik çizgi çiziyoruz.

Çıktısı;

```
Out[71]: <matplotlib.collections.LineCollection at 0x28781d210a0>
```

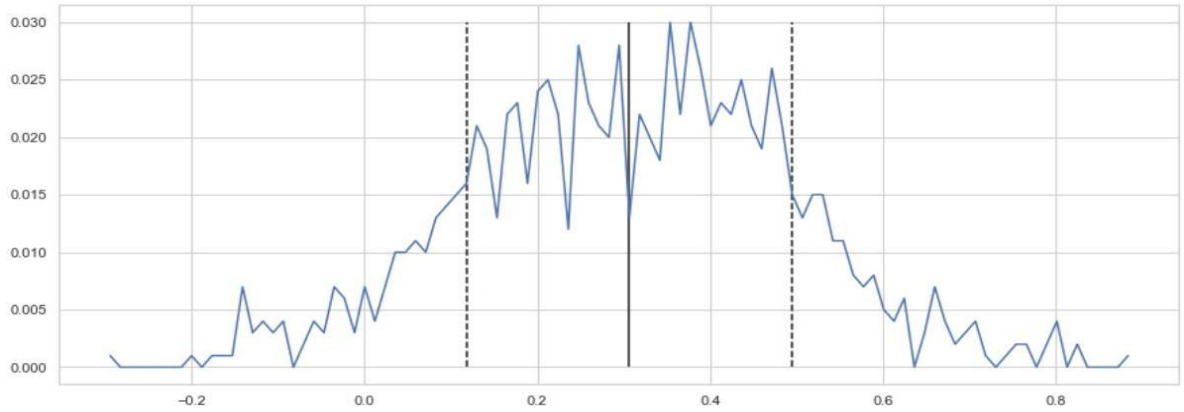


```
In [23]:
```

```python
# Modeli oluşturalım ve eğitelim.
def fit_model(train,val,timesteps,hl,lr,batch,epochs):
    X_train = []
    Y_train = []
    X_val = []
    Y_val = []

    # Eğitim verileri için döngü
    for i in range(timesteps,train.shape[0]):
        X_train.append(train[i-timesteps:i])
        Y_train.append(train[i][0])
    X_train,Y_train = np.array(X_train),np.array(Y_train)

    # Val verileri için döngü
    for i in range(timesteps,val.shape[0]):
        X_val.append(val[i-timesteps:i])
        Y_val.append(val[i][0])
    X_val,Y_val = np.array(X_val),np.array(Y_val)

    # Modele Katmanlar Ekleme
    model = Sequential()
    model.add(SimpleRNN(X_train.shape[2],input_shape = (X_train.shape[1],X_train.shape[2]),return_sequences = True,
                        activation = 'relu'))
    for i in range(len(hl)-1):
        model.add(SimpleRNN(hl[i],activation = 'relu',return_sequences = True))
    model.add(SimpleRNN(hl[-1],activation = 'relu'))
    model.add(Dense(1))
    model.compile(optimizer = optimizers.Adam(lr = lr), loss = 'mean_squared_error')


    # Verilerin eğitimi
    history = model.fit(X_train,Y_train,epochs = epochs,batch_size = batch,validation_data = (X_val, Y_val),verbose = 0,
                        shuffle = False, callbacks=callbacks_list)
    model.reset_states()
    return model, history.history['loss'], history.history['val_loss']

```

- Öncelikle X_train, Y_train, X_val ve Y_val oluşturuyoruz.
- Eğitim verilerimiz için döngü oluşturuyoruz ve burda X_train ile Y_traini kullanıp Numpay Array'a dönüştürüp tekrar kendisine eşitliyoruz.

- Eğitim verilerimiz için döngü oluşturuyoruz ve burda X_val ile Y_val kullanıp Numpay Array'a dönüştürüp tekrar kendisine eşitliyoruz.
- Modele katman ekleme işlemi gerçekleştiriyoruz.
- Bu modelde katman olarak RNN modeli kullanacağımız için RNN modelinin katmanlarını yazıyoruz.
- Model.fit ile Verilerin eğitimini gerçekleştiriyoruz .
- X_train, Y_train, X_val ve Y_val gerekli yerlere yazıyoruz ve history'e eşitliyoruz.
- Model.reset.states'i birbirini izleyen model aramaları bağımsız yapmak istediğimizde her seferinde araması için yazdık.
- Modelde elde ettiğimiz loss ve val_loss değerlerini history.history içerisinde belirttik.

In [17]:
```
# Modeli değerlendirme
def evaluate_model(model,test,timesteps):
    X_test = []
    Y_test = []

    # Verileri test etmek için döngü
    for i in range(timesteps,test.shape[0]):
        X_test.append(test[i-timesteps:i])
        Y_test.append(test[i][0])
    X_test,Y_test = np.array(X_test),np.array(Y_test)
    #print(X_test.shape,Y_test.shape)

    # Tahmin
    Y_hat = model.predict(X_test)
    mse = mean_squared_error(Y_test,Y_hat)
    rmse = sqrt(mse)
    r = r2_score(Y_test,Y_hat)
    return mse, rmse, r, Y_test, Y_hat
```

- Modeli test etmek için X_test ve Y_test oluşturuyoruz.
- Oluşturduğumuz X_test ve Y_test'i verileri test etmesi için döngüye sokuyoruz.
- Np.array ile X_test ile Y_test'i diziye dönüştürdük ve kendisine eşitledik.
- Tahmin değerlerimizi model.predict içerisine X_test şeklinde yazıyoruz ve Y_hat 'a ekliyoruz.
- Y_test ve Y_hat arasında mse değeri hesaplandı.
- Ssqrt ile mse değerinin karekökü alındı ve rmse değeri bulundu.

- R2_score yani belirleme katsayısı, bağımlı değişken içindeki bağımsız değişkenden tahmin edilebilir varyansın oranını hesaplar yani Y_test ile Y_hat arasındaki varyansın oranı hesaplandı ve r'ye eşitlendi.

In [25]:
```
# Tahminleri çizmek
def plot_data(Y_test,Y_hat):
    plt.plot(Y_test,c = 'red')
    plt.plot(Y_hat,c = 'green')
    plt.xlabel('Gün')
    plt.ylabel('Enerji')
    plt.title("RNN Tahmin Modeli")
    plt.legend(['Gercek','Tahmin'],loc = 'lower right')
    plt.show()
```

- Plot_error ile güven aralıkları(Y_test ve Y_hat) ile çizgi çizeceğiz.
- Plt.plot ile Y_test'i yazdıracağız ve rengini kısaltma red ile kırmızı yapıyoruz.
- Plt.plot ile Y_hat 'ı yazdıracağız ve rengini kısaltma green ile yeşil yapıyoruz.
- X ekseni üzerinde bir etiket oluşturuyoruz ve adını 'Gün' koyuyoruz.
- Y ekseni üzerinde bir etiket oluşturuyoruz ve adını 'Enerji' koyuyoruz.
- Grafiğe başlık olarak title ile 'RNN Tahmin Modeli' yazıyoruz.
- Plt.legend ile çalıştırıyoruz.
- Plt.show ile ekrana gösteriyoruz.
- Unutmamak gerekirki bu grafiği ileriki kısımlarda tek tek yazmak yerine sadece plot_data yazıp geçeceğiz ve grafiğimiz oluşacak.

In [26]:
```
# Eğitim hatalarının grafiğini çizme
def plot_error(train_loss,val_loss):
    plt.plot(train_loss,c = 'r')
    plt.plot(val_loss,c = 'b')
    plt.ylabel('Loss')
    plt.xlabel('Epochs')
    plt.title('Loss Plot')
    plt.legend(['train','val'],loc = 'upper right')
    plt.show()
```

- Plot_error ile güven aralıkları(train_loss ve val_loss) ile çizgi çizeceğiz.
- Plt.plot ile train_loss'u yazdıracağız ve rengini kısaltma r(red) ile kırmızı yapıyoruz.
- Plt.plot ile vall_loss'u yazdıracağız ve rengini kısaltma b(blue) ile mavi yapıyoruz.

- Y ekseni üzerinde bir etiket oluşturuyoruz ve adını ‘Loss’ koyuyoruz.
- X ekseni üzerinde bir etiket oluşturuyoruz ve adını ‘Epochs’ koyuyoruz.
- Grafiğe başlık olarak title ile ‘Loss Plot’ yazıyoruz.
- Plt.legend ile çalıştırıyoruz.
- Plt.show ile ekrana gösteriyoruz.
- Unutmamak gerekirki bu grafiği ileriki kısımlarda tek tek yazmak yerine sadece plot_error yazıp geçeceğiz ve grafiğimiz oluşacak.

In [27]:
```
# Seriyi ekrana çıkarma
series = df[['Global_active_power','Global_reactive_power','Voltage']] # Özellikleri seçtik.3 Giriş.
print(series.shape)
print(series.tail())
```

```
(1442, 3)
            Global_active_power  Global_reactive_power    Voltage
datetime
2010-11-22             2041.536                142.354  345883.85
2010-11-23             1577.536                137.450  346428.76
2010-11-24             1796.248                132.460  345644.59
2010-11-25             1431.164                116.128  347812.21
2010-11-26             1488.104                120.826  303487.57
```

- Veri setimiz olan df üzerinde Global_active_power , Global_reactive_power ve Voltage’yi seçiyoruz ve series’e eşitliyoruz bu kısmı yapmamızdaki amaç modele 3 giriş sağlamak.
- Series.shape’i print ile ekrana yazdırıyoruz ve kaç tane satır ve sütun verimizin olduğunu ekranda görüyoruz.
- Print kullanmasaydık series.shape gözükmeyecekti.
- Print.series.tail ile tail metodunu kullanarak son 5 veriyi ekrana gösterttik.

In [28]:
```
# Train,Val,Test Bölümü
train_start = dt.date(2006,12,16)
train_end = dt.date(2009,1,24)
train_data = series.loc[train_start:train_end]

val_start = dt.date(2009,1,25)
val_end = dt.date(2010,1,25)
val_data = series.loc[val_start:val_end]

test_start = dt.date(2010,1,26)
test_end = dt.date(2010,11,26)
test_data = series.loc[test_start:test_end]

print(train_data.shape,val_data.shape,test_data.shape)
```

```
(771, 3) (366, 3) (305, 3)
```

- Bu bölümde Train,Val,Test Bölümünün başlangıç(start) ve bitiş(end) bölümlerinin tarihlerini ayırdık.

- Daha sonra print ile train_data.shape , val_data.shape, test_data.shape ile ekrana veri sayısını(sütunları ve satırlarını) gösterttik.

In [29]:
```
# Normalizasyon
sc = MinMaxScaler()
train = sc.fit_transform(train_data)
val = sc.transform(val_data)
test = sc.transform(test_data)
print(train.shape,val.shape,test.shape)
```

```
(771, 3) (366, 3) (305, 3)
```

- MinMaxScaler'i sc'ye eşitliyoruz.
- train_data'nın eğitim setine parametrelerin uydurulması için sc.fit_transform() methodunu kullandık ve train'e eşitledik.
- val_data'nın eğitim setine parametrelerin uydurulması için sc.transform() methodunu kullandık ve val'a eşitledik.
- test_data'nın eğitim setine parametrelerin uydurulması için sc. transform() methodunu kullandık ve test'e eşitledik.
- Son olarak print ile train.shape, val.shape, test.shape ile ekrana veri sayısını(sütunları ve satırlarını) gösterttik.

In [30]:
```
#Hiperparametre ayarı
timesteps = 30
hl = [50,45]
lr = 1e-3
batch_size = 64
num_epochs = 200
```

- 'timesteps' ayarını 30 yapıyoruz.
- 'hl' ayarını 50,45 yapıyoruz.
- 'lr' ayarını 1e-3 yapıyoruz.
- 'Batch_size' ile alt küme boyutunu 64 yapıyoruz.

- ‘Num_epochs’ ile veri kümemizin yalnızca bir kez sinir ağından ileri ve geri aktarılmasıdır. Biz 200 kez ileri geri aktardık.

Not!

Burada Hiperparametre ayarlarını ayarlıyoruz. Burdaki değişiklik tahmin modelini etkileyecektir.

```
In [31]:
#Bu işlem 5-10 dakika arası sürebilir.
model,train_error,val_error = fit_model(train,val,timesteps,hl,lr,batch_size,num_epochs)
```

```
Epoch 00101: early stopping
```

- Burdaki işlemde model,train_error,val_error u fit modele eşitledik. Model içerisinede gerekli parametreleri yazdık.

```
In [32]:
plot_error(train_error,val_error)
```

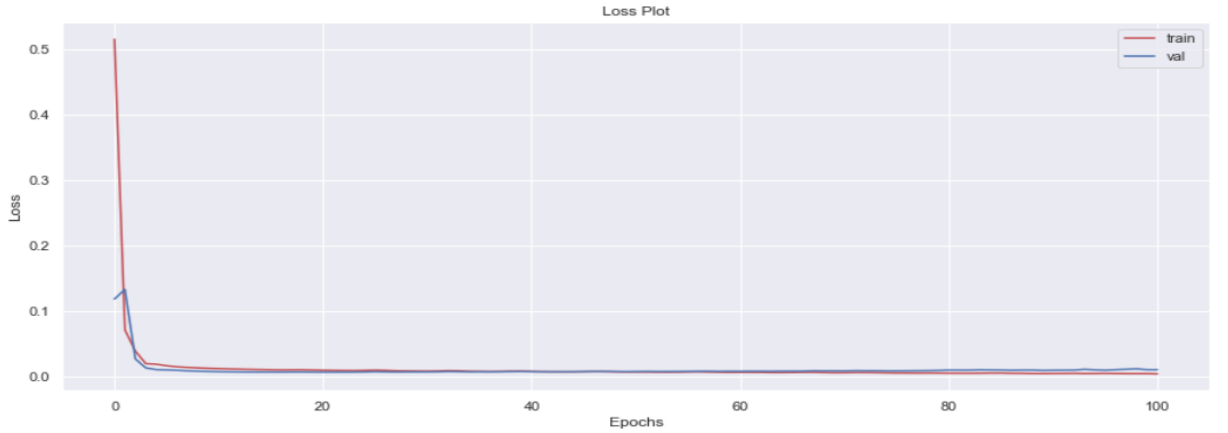

- Burada grafiği yukarıda tanımladığımız kısaltmayı kullanacağız.
- Plot_error diyerek kısaltmamızı kullanıyoruz ve içine çıkan sonuç değerlerini atıyoruz.
- Bu kod bölümünü çalıştırdığımız zaman direk yukarıdaki kod bloğu otomatikmen çalışıp bize sonucu yani çıktıyı verecektir.

```
In [34]:
mse, rmse, r2_value,true,predicted = evaluate_model(model,test,30)
print('MSE = {}'.format(mse))
print('RMSE = {}'.format(rmse))
print('R-Squared Score = {}'.format(r2_value))
```

```
MSE = 0.008170942227135165
RMSE = 0.09039326427967498
R-Squared Score = 0.06842176421588086
```

- Mse,rmse,r2_value,true,predicted girdileri belirleyerek evaluate_modelde çıktılarını bulmasını sağladık.

- Print ile ‘MSE’ değerini yazdırmasını istedik.
- Print ile ‘RMSE’ değerini yazdırmasını istedik.
- Print ile ‘R2-Score’ değerini yazdırmasını istedik.

3.3.4 Tahmin Modeli ve Gerçek Veri ile Kıyaslanması

Tahmin Modeli vs Gerçek Veri

```
In [35]: 1 plot_data(true,predicted)
```

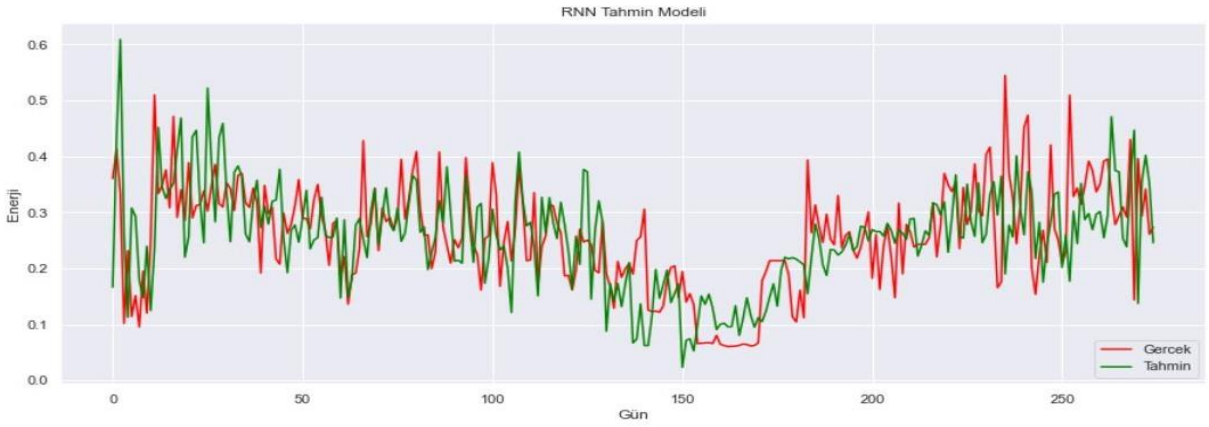

- Buradada grafiği yukarıda tanımladığımız kısaltmayı yani plot_data’yı kullanacağız.
- Plot_data diyerek kısaltmamızı kullanıyoruz ve içine çıkan tahmin ve gerçek değerlerini atıyoruz.
- Bu kod bölümünü çalıştırdığımız zaman direk yukarıdaki kod bloğu otomatikmen çalışıp bize sonucu yani çıktıyı verecektir.

3.3.5 K-FOLD VE GRİDSEARCHCV

K-FOLD VE GRİDSEARCHCV

```
In [84]:
from numpy import mean
from numpy import std
from sklearn.datasets import make_classification
from sklearn.model_selection import KFold
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score

```

- Öncelikle önemli kütüphaneleri import ediyoruz.
- Bunlar sklearn kütüphanesi içerisindeki make_classification, KFold, GridSearchCV, RandomForestClassifier ve accuracy_score.

```
In [85]:
#Veri setmizi tekrar tanımlamamızdaki amaç altta x1 ve y1'i ayarlarken bir sorunla karşılaşmamak.
df = pd.read_csv('household_daily.csv')
df.head()
```

Out[85]:

	datetime	Global_active_power	Global_reactive_power	Voltage	Global_intensity	Sub_metering_1	Sub_metering_2	Sub_metering_3	Sub_metering_4
0	2006-12-16	1209.176	34.922	93552.53	5180.8	0.0	546.0	4926.0	14680.933319
1	2006-12-17	3390.460	226.006	345725.32	14398.6	2033.0	4187.0	13341.0	36946.666732
2	2006-12-18	2203.826	161.792	347373.64	9247.2	1063.0	2621.0	14018.0	19028.433281
3	2006-12-19	1666.194	150.942	348479.01	7094.0	839.0	7602.0	6197.0	13131.900043
4	2006-12-20	2225.748	160.998	348923.61	9313.0	0.0	2648.0	14063.0	20384.800011

- Burada veri setimizi tekrardan tanımlayıp göstermekteki amacımız ileride veri setini ikiye ayıracağımızda sıkıntı olmasın diye.

```
In [86]:
x1 = df.iloc[:,1:3]
y1 = df.iloc[:,3:4]
```

- Burda veri seti(df) üzerinde iloc ile ayırma işlemi yaptık.
- x1 için satırlar arası 1 ile 3 arasında.
- y2 içinde 3ile4 arasındaki sütunları alacaktır.

```
In [87]:
x1
```

Out[87]:

	Global_active_power	Global_reactive_power
0	1209.176	34.922
1	3390.460	226.006
2	2203.826	161.792
3	1666.194	150.942
4	2225.748	160.998
...	...	...
1437	2041.536	142.354
1438	1577.536	137.450
1439	1796.248	132.460
1440	1431.164	116.128
1441	1488.104	120.826

1442 rows × 2 columns

- x1'in görüntüsü yukarıdaki gibidir.

```
In [88]:  1  y1
```

Out[88]:

	Voltage
0	93552.53
1	345725.32
2	347373.64
3	348479.01
4	348923.61
...	...
1437	345883.85
1438	346428.76
1439	345644.59
1440	347812.21
1441	303487.57

1442 rows × 1 columns

- y1'in görüntüsü yukarıdaki gibidir.

```
In [89]:
1 import warnings
2 warnings.simplefilter(action='ignore', category=FutureWarning)
3
4 x1_np = x1.to_numpy()
5 y1_np = y1.to_numpy()
6 x1_np ,y1_np = make_classification( random_state=1, n_informative=10, n_redundant=10)
7
```

- Öncelikle x1 verimizi ve y1 verimizi numpy array'a dönüştürüp x1_np ve y1_np'ye eşitliyoruz.
- Make_classification ile rastgele bir sınıf oluşturuyoruz
- random_state parametresi train ve test endeksleri içine verilerin bölme karar verecek iç rasgele sayı üretecidir ve biz random_state=1 yapıyoruz.
- bilgilendirici yani informative değerini 10 yapıyoruz.
- Gereksiz yani redundant değerini 10 yapıyoruz.
- Oluşturduğumuz rastgele sınıfı x1_np ve y1_np'ye eşitliyoruz.

```
# Çapraz doğrulama prosedürünü yapılandıralım
cv_outer = KFold(n_splits=10, shuffle=True, random_state=1)
# Bölmeleri numaralandıralım
outer_results = list()
for train_ix, test_ix in cv_outer.split(x1_np):
    # Verileri bölelim
    X_train, X_test = x1_np[train_ix, :], x1_np[test_ix, :]
    y_train, y_test = y1_np[train_ix], y1_np[test_ix]
    # Çapraz doğrulama prosedürünü yapılandıralım
    cv_inner = KFold(n_splits=3, shuffle=True, random_state=1)
    # Modeli tanımlayalım
    model = RandomForestClassifier(random_state=1)
    # Arama alanını tanımlayalım
    space = dict()
    space['n_estimators'] = [10, 100, 500]
    space['max_features'] = [2, 4, 6]
    # Aramayı tanımlayalım
    search = GridSearchCV(model, space, scoring='accuracy', cv=cv_inner, refit=True)
    # aramayı yapalım
    result = search.fit(X_train, y_train)
    # Tüm eğitim setinde en iyi performans gösteren modeli elde edelim
    best_model = result.best_estimator_
    # Geciktirme veri kümesinde modeli değerlendirme
    yhat = best_model.predict(X_test)
    # Modeli değerlendirme
    acc = accuracy_score(y_test, yhat)
    # Sonucu saklayalım
    outer_results.append(acc)
    # İlerlemeleri ekrana yazdıralım
    print('acc=%.3f, est=%.3f, cfg=%s' % (acc, result.best_score_, result.best_params_))
# Modelin tahmini performansını gösterelim
print('Accuracy: %.3f (%.3f)' % (mean(outer_results), std(outer_results)))
```

Not:Bir önceki kod bloğuna devam ediyoruz.(Sığmadığı için ayrımıştır.)

- Öncelikle Çapraz doğrulama yani Kfold'u yapılandıralım.
- Kfold 'un içerisindeki n_split kısmını 10 yapıyoruz bu bizim katman sayımızı temsil edecektir ve bu bölümü cv_outer'a eşitliyoruz.
- Bölmeleri numaralandırmak için list() ile listeliyoruz ve outer_results'a eşitliyoruz.
- Daha sonra döngü oluşturarak x1_np split'i ile döngü oluşturuyoruz ve içerisine tanımlı train_ix ve test_ix 'i yazıyoruz.
- X_train,X_test,y_train_y_test'i oluşturuyoruz.
- Kfold'u döngü içerisinde tekrar kullanıyoruz ve burada 3 katman kullanıyoruz ve cv_inner'e eşitliyoruz.
- RandomForestClassifier ile model oluşturuyoruz ve model'a eşitliyoruz.
- Daha sonra arama alanını tanımlıyoruz ve space bölümleri oluşturuyoruz.
- İlk olarak space=dict() ile bir sözlük oluşturuyoruz.
- İkinci space ile n_tahmincisini oluşturuyoruz ve tahmin değererini 10,100 ev 500 olarak ayarlıyoruz.
- Üçüncü space olarak da maksimum özelliğini oluşturuyoruz ve tahmin değerlerini 2,4,6 ayarlıyoruz.

- Daha sonra Aramayı tanımlayalım ve GridSearchCv ile tanımlayalım burdaki accuracy bizim doğruluk değerimizdir ve bu kısmı search'a eşitliyoruz.
- Search.fit(X_train,y_train) ile aramayı yapıyoruz ve bunuda result'a eşitliyoruz.
- Tüm eğitim setinde en iyi performans gösteren modeli elde etmek için (result.best_estimator_) parametresini kullanıyoruz ve best_model'a eşitliyoruz.
- Geciktirme veri kümesinde modeli değerlendirmek için ise best_model.predict(X_test) parametresini kullanıyoruz ve yhat'a eşitliyoruz.
- Modeli değerlendirmek için accuracy_score() methodunu kullanıyoruz ve içine parametre olarak y_test ve yhat'ı ekliyoruz ve bunuda acc'ye eşitliyoruz.
- outer_results.append()' metodu ile çıkan sonucu saklıyoruz. Yani acc'yi saklıyoruz.
- Print ile acc değerini, en iyi performans verisini(est) ve cfg(tahmin edicileri) ekrana yazdırıyoruz.
- Daha sonra döngüden çıkıyoruz ve en son olarak Modelin tahmini performansını Print ile ekrana yansıtıyoruz.

Çıktısı;

```
acc=0.900, est=0.867, cfg={'max_features': 6, 'n_estimators': 100}
acc=0.900, est=0.867, cfg={'max_features': 2, 'n_estimators': 500}
acc=0.900, est=0.867, cfg={'max_features': 4, 'n_estimators': 500}
acc=0.800, est=0.833, cfg={'max_features': 4, 'n_estimators': 100}
acc=0.900, est=0.867, cfg={'max_features': 6, 'n_estimators': 100}
acc=0.900, est=0.856, cfg={'max_features': 2, 'n_estimators': 100}
acc=0.800, est=0.911, cfg={'max_features': 2, 'n_estimators': 100}
acc=0.800, est=0.856, cfg={'max_features': 2, 'n_estimators': 100}
acc=0.900, est=0.878, cfg={'max_features': 6, 'n_estimators': 100}
acc=0.900, est=0.900, cfg={'max_features': 6, 'n_estimators': 100}
Accuracy: 0.870 (0.046)
```

4 Sonuç

Multivariable(Çok değişkenli) girişli 2006-2011 arasında bir bölgenin kullandığı elektrik tüketimini 'Jupyter Notebook' ile verileri ekrana göstererek daha sonra bu veri seti ile veri görselleştirmesi, güzelleştirmesi ve düzenlemesi yapılmıştır. Öncelikle modelde önce kütüphaneler belirlendi daha sonra veri seti ekrana yansıtılıp veri setini işledikten(düzenledikten) sonra grafikler ile güzelleştirme yapılıp modeller oluşturuldu. Grafik üzerinde gösterme yöntemini kullandığımız fonksiyonlar Çizgi grafiği için 'lineplot', Kutu grafiği için 'boxplot', Histogram grafiği için 'distplot', Violin(Keman) Grafiği için 'violinplot' fonksiyonlarını kullanarak veri seti grafiklere döküldü. 'corr' metodu ile ikili korelasyonlarını bulduk. 'df.describe()' metodu sayısal verilere sahip olan sütunların max, min , std…gibi istatiksel değerlerini her bir giriş için ekrana yansıttık. Daha sonra veri ön işleme adımları uygulanarak model geliştirildi. RNN modelinde Çeşitli grafiklerle veri görselleştirilmesi yapıldı. Bu modelde MSE ve RMSE değerleri hesaplandı. Karşılaştırma grafiği için matplotlib kütüphanesi kullanıldı. Çeşitli metodlarla verileri hakkında bilgi edinildi. Sonuç olarak bu modelin tahmin grafikleri oluşturuld. Bu modelde düzenlenen gerçek veriler o tahmin model ile karşılaştırıldı. Daha sonra ekleme yapılarak jackknife ve bootstrap ile veri arttırma teknikleri kullanıldı. Modelin eğitimi tamamlandıktan sonra k katlamalı çapraz doğrulama(k fold cross validation) ile birlikte GridSearchCV ile doğruluk değerlerini ve tahmin edicileri bulduk.

KAYNAKÇA

- https://machinelearningmastery.com/decompose-time-series-data-trend-seasonality/#:~:text=The%20statsmodels%20library%20provides%20an,model%20is%20additive%20or%20multiplicative.&text=The%20seasonal_decompose()%20function%20returns%20a%20result%20object.
- https://stackoverflow.com/questions/61040284/problems-with-acf-plots-and-operands
- https://numpy.org/doc/stable/reference/generated/numpy.diff.html
- https://www.researchgate.net/post/What-is-the-window-size-in-neural-networks-and-how-it-effects-training
- https://www.tutorialspoint.com/numpy/numpy_concatenate.htm#:~:text=numpy.-,concatenate,shape%20along%20a%20specified%20axis.
- https://tr.wikipedia.org/wiki/Dickey_Fuller_testi
- https://www.machinelearningplus.com/time-series/augmented-dickey-fuller-test/
- https://dergipark.org.tr/tr/download/article-file/29738
- https://medium.com/@tuncerergin/keras-ile-derin-ogrenme-modeli-olusturma-4b4ffdc35323
- https://numpy.org/doc/stable/reference/generated/numpy.mean.html
- https://en.wikipedia.org/wiki/Additive_model
- https://en.wikipedia.org/wiki/Decomposition_of_time_series
- http://omz-software.com/pythonista/matplotlib/users/tight_layout_guide.html#:~:text=tight_layout%20automatically%20adjusts%20subplot%20params,%2C%20axis%20labels%2C%20and%20titles.
- https://www.statsmodels.org/stable/generated/statsmodels.graphics.tsaplots.plot_acf.html
- https://www.geeksforgeeks.org/python-coefficient-of-determination-r2-score/
- https://stackoverflow.com/questions/42763928/how-to-use-model-reset-states-in-keras#:~:text=If%20you%20use%20explicitly%20either,model%2C%20or%20layer.reset_states()
- https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.corr.html
- https://towardsdatascience.com/pandas-for-people-in-a-hurry-59d966630ae0#:~:text=Exploring%20DataFrame,5%20rows%20of%20the%20dataframe.&text=tail()%20Returns%20the%20last%205%20rows%20of%20the%20dataframe.
- https://machinelearningmastery.com/early-stopping-to-avoid-overtraining-neural-network-models/

- https://machinelearningmastery.com/how-to-stop-training-deep-neural-networks-at-the-right-time-using-early-stopping/
- https://ishakdolek.medium.com/lstm-d2c281b92aac#:~:text=LSTM(Long%2D%20Short%20Term%20Memory,taraf%C4%B1ndan%20at%C4%B1f%20ald%C4%B1%20ve%20yayg%C4%B1nla%C5%9Ft%C4%B1r%C4%B1ld%C4%B1.
- https://www.rdocumentation.org/packages/statisticalModeling/versions/0.3.0/topics/evaluate_model
- https://www.researchgate.net/post/Can-anyone-explain-batch-size-batch-input-shape-return-sequenceTrue-False-in-python-during-training-LSTM-with-KERAS#:~:text=batch_size%20denotes%20the%20subset%20size,appliance%20of%20the%20previous%20batch.
- https://en.wikipedia.org/wiki/Gated_recurrent_unit
- https://www.geeksforgeeks.org/python-pandas-to_datetime/
- https://www.geeksforgeeks.org/matplotlib-axis-axis-get_ticklabels-function-in-python/
- https://stackoverflow.com/questions/61443261/what-is-the-use-of-pd-plotting-register-matplotlib-converters-in-pandas
- https://nextjournal.com/blog/plotting-pandas-prophet
- https://pythonbasics.org/seaborn-distplot/#:~:text=We%20use%20seaborn%20in%20combination,()%20and%20rugplot()%20functions.
- https://www.geeksforgeeks.org/matplotlib-figure-figure-add_subplot-in-python/#:~:text=matplotlib.-,figure.,part%20of%20a%20subplot%20arrangement.
- https://literarydevices.net/subplot/
- https://pythonprogramming.net/subplot2grid-add_subplot-matplotlib-tutorial/
- https://www.splashlearn.com/math-vocabulary/geometry/line-plot#:~:text=A%20Line%20plot%20can%20be,the%20frequency%20of%20each%20value.
- https://tr.wikipedia.org/wiki/Kutu_grafi%C4%9Fi
- https://www.mathsisfun.com/data/histograms.html#:~:text=Histogram%3A%20a%20graphical%20display%20of,many%20fall%20into%20each%20range.
- https://en.wikipedia.org/wiki/Violin_plot
- https://aditi-mittal.medium.com/understanding-rnn-and-lstm-f7cdf6dfc14e